Análisis de la segunda ola de la COVID-19

Objetivo

El objetivo principal de este proyecto es poder analizar la evolución de la pandemia COVID-19 en esta segunda ola, haciendo uso de algoritmos de Machine Learning, y así poder realizar predicciones de su evolución.

Prerrequisitos

Para poder realizar el proyecto debemos tener instalados en nuestro sistema una serie de librerías de Data Science y Machine Learning. A continuación quedan indicadas las mismas:

- Numpy
- Pandas
- Scikit-Learn
- MatplotLib
- Seaborn

Todas estas librerías estan ya instaladas en el entorno de trabajo de ANACONDA 3. Solo deberemos importar las mismas.

Configuración del entorno

In [1]:
```
import warnings
warnings.filterwarnings("ignore")
import datetime
import numpy as np
import pandas as pd
import sklearn
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
```

Dataset

Para analizar este problema vamos a descargarnos un dataset que pone a disposición la Unión Europea en la siguiente url:

https://www.ecdc.europa.eu/en/publications-data/download-todays-data-geographic-distribution-covid-19-cases-worldwide

In [2]:
```
df = pd.read_excel("../Modulo 3/Dataset/COVID-19-geographic-disbtribution-worldwide-2020-11-03.xlsx")
```

Comprobamos los datos que hemos cargado en nuestro dataFrame

In [3]:
```
df.head(10)
```

Out[3]:

	dateRep	day	month	year	cases	deaths	countriesAndTerritories	geoId	countryterritoryCode	popData2019	continentExp
0	2020-11-03	3	11	2020	95	3	Afghanistan	AF	AFG	38041757.0	Asia
1	2020-11-02	2	11	2020	132	5	Afghanistan	AF	AFG	38041757.0	Asia
2	2020-11-01	1	11	2020	76	0	Afghanistan	AF	AFG	38041757.0	Asia
3	2020-10-31	31	10	2020	157	4	Afghanistan	AF	AFG	38041757.0	Asia
4	2020-10-30	30	10	2020	123	3	Afghanistan	AF	AFG	38041757.0	Asia
5	2020-10-29	29	10	2020	0	0	Afghanistan	AF	AFG	38041757.0	Asia
6	2020-10-28	28	10	2020	113	7	Afghanistan	AF	AFG	38041757.0	Asia
7	2020-10-27	27	10	2020	199	8	Afghanistan	AF	AFG	38041757.0	Asia
8	2020-10-26	26	10	2020	65	3	Afghanistan	AF	AFG	38041757.0	Asia
9	2020-10-25	25	10	2020	81	4	Afghanistan	AF	AFG	38041757.0	Asia

In [4]:
```
df.tail(10)
```

Out[4]:

	dateRep	day	month	year	cases	deaths	countriesAndTerritories	geoId	countryterritoryCode	popData2019	continentExp
53156	2020-03-30	30	3	2020	0	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53157	2020-03-29	29	3	2020	2	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53158	2020-03-28	28	3	2020	2	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53159	2020-03-27	27	3	2020	0	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53160	2020-03-26	26	3	2020	1	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53161	2020-03-25	25	3	2020	0	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53162	2020-03-24	24	3	2020	0	1	Zimbabwe	ZW	ZWE	14645473.0	Africa
53163	2020-03-23	23	3	2020	0	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53164	2020-03-22	22	3	2020	1	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53165	2020-03-21	21	3	2020	1	0	Zimbabwe	ZW	ZWE	14645473.0	Africa

Comprobamos la info del DataFrame con el objetivo de determinar las columnas del df y el tipo de datos que contiene cada una de ellas. De esta forma, podremos realizar cualquier cambio de forma correcta según la tipología de los datos.

También se comprobarán los datos estadísticos principales.

In [5]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53166 entries, 0 to 53165
Data columns (total 12 columns):
 #   Column                                                      Non-Null Count  Dtype
---  ------                                                      --------------  -----
 0   dateRep                                                     53166 non-null  datetime64[ns]
 1   day                                                         53166 non-null  int64
 2   month                                                       53166 non-null  int64
 3   year                                                        53166 non-null  int64
 4   cases                                                       53166 non-null  int64
 5   deaths                                                      53166 non-null  int64
 6   countriesAndTerritories                                     53166 non-null  object
 7   geoId                                                       52932 non-null  object
 8   countryterritoryCode                                        53084 non-null  object
 9   popData2019                                                 53084 non-null  float64
 10  continentExp                                                53166 non-null  object
 11  Cumulative_number_for_14_days_of_COVID-19_cases_per_100000  50348 non-null  float64
dtypes: datetime64[ns](1), float64(2), int64(5), object(4)
memory usage: 4.9+ MB
```

In [6]:
```
df.describe()
```

Out[6]:

	day	month	year	cases	deaths	popData2019	Cumulative_number_for_14_days_of_COVID-19_cases_per_100000
count	53166.000000	53166.000000	53166.000000	53166.000000	53166.000000	5.308400e+04	50348.000000
mean	15.936708	6.366512	2019.998740	885.770038	22.707934	4.175643e+07	45.824057
std	8.918328	2.575420	0.035477	4977.075371	124.073255	1.550772e+08	112.109316
min	1.000000	1.000000	2019.000000	-8261.000000	-1918.000000	8.150000e+02	-147.419587
25%	8.000000	4.000000	2020.000000	0.000000	0.000000	1.324820e+06	0.555858
50%	16.000000	6.000000	2020.000000	12.000000	0.000000	7.813207e+06	5.652028
75%	24.000000	9.000000	2020.000000	202.000000	3.000000	2.860872e+07	39.292731
max	31.000000	12.000000	2020.000000	101273.000000	4928.000000	1.433784e+09	1900.836210

El primer paso será cambiar el nombre de la columna 'Cumulative_number_for_days_of_COVID-19_cases_per_100000'

In [7]:
```
df = df.rename(
    {"Cumulative_number_for_14_days_of_COVID-19_cases_per_100000": 'Cum14_cases_100k'}, axis = 1)
df
```

Out[7]:

	dateRep	day	month	year	cases	deaths	countriesAndTerritories	geoId	countryterritoryCode	popData2019	continentExp
0	2020-11-03	3	11	2020	95	3	Afghanistan	AF	AFG	38041757.0	Asia
1	2020-11-02	2	11	2020	132	5	Afghanistan	AF	AFG	38041757.0	Asia
2	2020-11-01	1	11	2020	76	0	Afghanistan	AF	AFG	38041757.0	Asia
3	2020-10-31	31	10	2020	157	4	Afghanistan	AF	AFG	38041757.0	Asia
4	2020-10-30	30	10	2020	123	3	Afghanistan	AF	AFG	38041757.0	Asia
...	...	...	...	...	...	...	...	...	...	...	...
53161	2020-03-25	25	3	2020	0	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53162	2020-03-24	24	3	2020	0	1	Zimbabwe	ZW	ZWE	14645473.0	Africa
53163	2020-03-23	23	3	2020	0	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53164	2020-03-22	22	3	2020	1	0	Zimbabwe	ZW	ZWE	14645473.0	Africa
53165	2020-03-21	21	3	2020	1	0	Zimbabwe	ZW	ZWE	14645473.0	Africa

53166 rows × 12 columns

También se utilizará la columna dateRep como índice del DataFrame.

In [8]:
```
df.set_index('dateRep', inplace=True)
```

Y ordenamos el DataFrame por el nuevo índice marcado. De esta forma tendremos ordenado el df mediante la fecha de los datos.

In [9]:
```
df.sort_index(inplace=True)
df
```

Out[9]:

dateRep	day	month	year	cases	deaths	countriesAndTerritories	geoId	countryterritoryCode	popData2019	continentExp
2019-12-31	31	12	2019	0	0	Nigeria	NG	NGA	200963603.0	Africa
2019-12-31	31	12	2019	0	0	Finland	FI	FIN	5517919.0	Europe
2019-12-31	31	12	2019	0	0	Singapore	SG	SGP	5804343.0	Asia
2019-12-31	31	12	2019	0	0	Luxembourg	LU	LUX	613894.0	Europe
2019-12-31	31	12	2019	0	0	Netherlands	NL	NLD	17282163.0	Europe
...	...	...	...	...	...	...	...	...	...	...
2020-11-03	3	11	2020	0	0	Saint_Lucia	LC	LCA	182795.0	America
2020-11-03	3	11	2020	28	0	Mali	ML	MLI	19658023.0	Africa
2020-11-03	3	11	2020	0	0	Haiti	HT	HTI	11263079.0	America
2020-11-03	3	11	2020	193	13	Honduras	HN	HND	9746115.0	America
2020-11-03	3	11	2020	95	3	Afghanistan	AF	AFG	38041757.0	Asia

53166 rows × 11 columns

Análisis de los datos

Qué países son los que tienen mayor incidencia de COVID con los datos disponibles?

Generamos un dataframe por país:

In [10]:
```
df_countries = df[['countriesAndTerritories', 'Cum14_cases_100k']].\
        groupby('countriesAndTerritories').last()
df_countries
```

Out[10]:

countriesAndTerritories	Cum14_cases_100k
Afghanistan	3.787943
Albania	145.785377
Algeria	9.193308
Andorra	1660.606220
Angola	10.724173
...	...
Wallis_and_Futuna	NaN
Western_Sahara	0.000000
Yemen	0.010287
Zambia	3.616812
Zimbabwe	1.570451

213 rows × 1 columns

Generamos un dataframe con los datos del indicador de Casos por 100.000 habitantes en los últimos 14 días

In [11]:
```
df_countries.sort_values(by=['Cum14_cases_100k'], ascending=False).\
        nlargest(25,'Cum14_cases_100k')
```

Out[11]:

countriesAndTerritories	Cum14_cases_100k
Belgium	1753.181152
Andorra	1660.606220
Czechia	1586.264531
Luxembourg	1337.853115
French_Polynesia	1240.668135
Slovenia	1082.460157
Switzerland	1081.522710
Armenia	991.166192
Liechtenstein	990.150607
France	829.924001
Netherlands	762.410353
Croatia	654.695521
Georgia	598.384392
Slovakia	571.221929
Spain	567.244732
Guam	560.088466
Poland	558.905145
Montenegro	554.500130
Austria	537.986347
Bosnia_and_Herzegovina	533.293265
Italy	510.292109
San_Marino	470.205788
United_Kingdom	469.115601
North_Macedonia	443.351698
Portugal	437.760792

Analizamos la situación actual por país de la pandemia del COVID

In [12]:
```
#Generamos un nuevo dataframe con los datos agrupados
df_agrup = df.groupby('countriesAndTerritories').agg(
    # Muertes
    muertes_COVID = ('deaths', 'sum'),
    # Población total
    población = ("popData2019", 'last'),
    # Total enfermos COVID
    enfermos_COVID = ('cases', 'sum'),
    # Situación actual casos por 100k
    cum14_casos_100k_ultimo_dia = ('Cum14_cases_100k', "last")
)
df_agrup
```

Out[12]:

countriesAndTerritories	muertes_COVID	población	enfermos_COVID	cum14_casos_100k_ultimo_dia
Afghanistan	1544	38041757.0	41728	3.787943
Albania	527	2862427.0	21523	145.785377
Algeria	1980	43053054.0	58574	9.193308
Andorra	75	76177.0	4888	1660.606220
Angola	286	31825299.0	11035	10.724173
...	...	...	...	...
Wallis_and_Futuna	0	NaN	1	NaN
Western_Sahara	1	582458.0	766	0.000000
Yemen	600	29161922.0	2063	0.010287
Zambia	349	17861034.0	16543	3.616812
Zimbabwe	245	14645473.0	8389	1.570451

213 rows × 4 columns

Se crearan nuevas variables para poder entender mejor el impacto de la pandemia. Las nuevas variables son las siguientes:

- Muertos por cada 100k habitantes
- Casos por cada 100k habitantes
- Indice mortalidad Covid

In [13]:
```
df_agrup['muertes_100k'] = df_agrup['muertes_COVID']/df_agrup['población']*100000
df_agrup['casos_100k'] = df_agrup['enfermos_COVID']/df_agrup['población']*100000
df_agrup['indice_mortalidad_COVID'] = df_agrup['muertes_COVID']/df_agrup['enfermos_COVID']*100
df_agrup
```

Out[13]:

countriesAndTerritories	muertes_COVID	población	enfermos_COVID	cum14_casos_100k_ultimo_dia	muertes_100k	casos_100k
Afghanistan	1544	38041757.0	41728	3.787943	4.058698	109.689991
Albania	527	2862427.0	21523	145.785377	18.410950	751.913372
Algeria	1980	43053054.0	58574	9.193308	4.598977	136.050143
Andorra	75	76177.0	4888	1660.606220	98.454914	6416.634942
Angola	286	31825299.0	11035	10.724173	0.898656	34.673673
...	...	...	...	...	...	...
Wallis_and_Futuna	0	NaN	1	NaN	NaN	NaN
Western_Sahara	1	582458.0	766	0.000000	0.171686	131.511628
Yemen	600	29161922.0	2063	0.010287	2.057478	7.074294
Zambia	349	17861034.0	16543	3.616812	1.953974	92.620618
Zimbabwe	245	14645473.0	8389	1.570451	1.672872	57.280499

213 rows × 7 columns

Ordenamos el df por el número de muertes provocadas por la COVID-19 y así vemos los países con mas muertes y vemos también que relación tienen con el índice de mortalidad.

In [14]:
```
df_agrup =df_agrup.sort_values(by = ['muertes_COVID'], ascending=False)
df_agrup.head(20)
```

Out[14]:

countriesAndTerritories	muertes_COVID	población	enfermos_COVID	cum14_casos_100k_ultimo_dia	muertes_100k	casos_100k
United_States_of_America	231551	3.290649e+08	9291245	327.136059	70.366359	2823.529498
Brazil	160253	2.110495e+08	5554206	143.795163	75.931469	2631.707490
India	123097	1.366418e+09	8267623	49.074304	9.008738	605.058223
Mexico	92100	1.275755e+08	933155	61.319754	72.192528	731.452973
United_Kingdom	46853	6.664711e+07	1053864	469.115601	70.300120	1581.259815
Italy	39059	6.035955e+07	731588	510.292109	64.710560	1212.050203
France	37435	6.701288e+07	1466433	829.924001	55.862393	2188.285199
Spain	36257	4.693706e+07	1240697	567.244732	77.245997	2643.320651
Iran	35738	8.291389e+07	628780	113.550331	43.102547	758.353006
Peru	34585	3.251046e+07	906545	109.715451	106.381140	2788.471600
Colombia	31670	5.033944e+07	1093256	253.028227	62.912893	2171.768170
Argentina	31623	4.478068e+07	1183118	403.006431	70.617515	2642.028062
Russia	28473	1.458723e+08	1655038	164.336934	19.519133	1134.580351
South_Africa	19465	5.855827e+07	727595	38.151744	33.240396	1242.514571
Chile	14302	1.895204e+07	513188	104.912217	75.464192	2707.825307
Indonesia	14044	2.706256e+08	415402	18.535573	5.189458	153.496953
Ecuador	12692	1.737366e+07	169562	92.893511	73.053129	975.971841
Belgium	11858	1.145552e+07	447260	1753.181152	103.513424	3904.318958
Iraq	11017	3.930979e+07	478701	122.165499	28.026098	1217.765376
Germany	10661	8.301921e+07	560379	225.504426	12.841606	674.999172

Al realizar la última comprobación se ha detectado que algunos paises tienen un índice de mortalidad muy alto. Este hecho puede venir dado porque, estos mismos paises no contabilizan todos los enfermos de COVID, peró sí las muertes, ya que estas es mas difícil esconderlas y/o obviarlas!!!

Esto puede distorsionar los datos

Vamos a realizar un histograma para ver la distribución de índices de mortalidad.

In [15]:
```
df_agrup['indice_mortalidad_COVID'].plot(kind= 'hist', title= 'Distribución paises por índice de mortalidad');
plt.show()
```

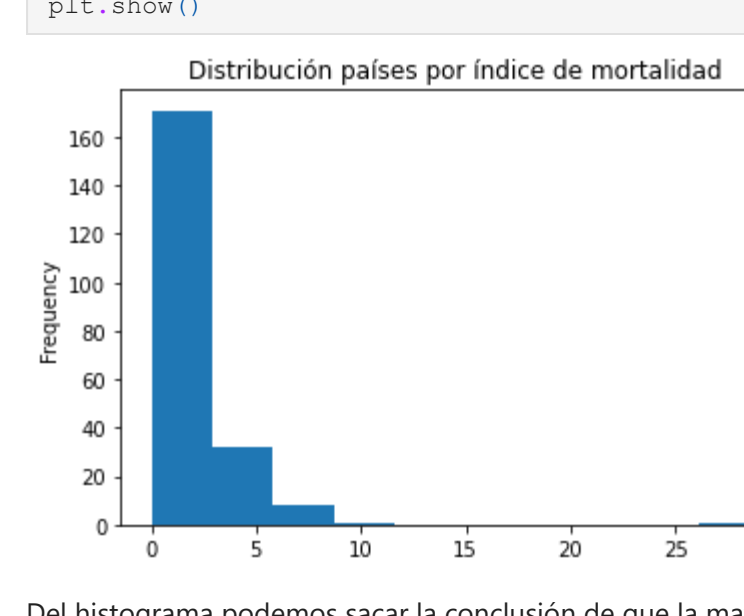

Del histograma podemos sacar la conclusión de que la mayor parte de paises tienen un índice de mortalidad que se encuentra entre el 0 y el 2,5%.

Por otra parte, podemos observar que existen algunos casos cuyo índice de kortalidad está en torno al 28%. Se trata de un índice muy superior a la media de los países afectados por la pandemia. Esto indica que los datos dispuestos de este país no son fiables o faltan parte de ellos.

Modelos

Diferenciar grupos de países aplicando un algoritmo de clustering a los datos

Creamos un nuevo dataframe con las variables mas representativas que dispongamos en nuestro dataset

In [16]:
```
variables_clustering = ['cum14_casos_100k_ultimo_dia',
                        'casos_100k',
                        'muertes_100k',
                        'indice_mortalidad_COVID']
df_clustering = df_agrup[variables_clustering]
df_clustering.head(20)
```

Out[16]:

countriesAndTerritories	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID
United_States_of_America	327.136059	2823.529498	70.366359	2.492142
Brazil	143.795163	2631.707490	75.931469	2.885255
India	49.074304	605.058223	9.008738	1.488904
Mexico	61.319754	731.452973	72.192528	9.869743
United_Kingdom	469.115601	1581.259815	70.300120	4.445830
Italy	510.292109	1212.050203	64.710560	5.338934
France	829.924001	2188.285199	55.862393	2.552793
Spain	567.244732	2643.320651	77.245997	2.922309
Iran	113.550331	758.353006	43.102547	5.683705
Peru	109.715451	2788.471600	106.381140	3.815034
Colombia	253.028227	2171.768170	62.912893	2.896851
Argentina	403.006431	2642.028062	70.617515	2.673853
Russia	164.336934	1134.580351	19.519133	1.720383
South_Africa	38.151744	1242.514571	33.240396	2.675252
Chile	104.912217	2707.825307	75.464192	2.786893
Indonesia	18.535573	153.496953	5.189458	3.380821
Ecuador	92.893511	975.971841	73.053129	7.485168
Belgium	1753.181152	3904.318958	103.513424	2.651254
Iraq	122.165499	1217.765376	28.026098	2.301437
Germany	225.504426	674.999172	12.841606	1.902462

In [17]:
```
df_clustering = df_clustering.sort_values(by = ['cum14_casos_100k_ultimo_dia'], ascending=False)
df_clustering.head(20)
```

Out[17]:

countriesAndTerritories	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID
Belgium	1753.181152	3904.318958	103.513424	2.651254
Andorra	1660.606220	6416.634942	98.454914	1.534370
Czechia	1586.264531	3294.859997	34.310503	1.041334
Luxembourg	1337.853115	3111.449208	26.063131	0.837652
French_Polynesia	1240.668135	2600.211254	10.383658	0.399339
Slovenia	1082.460157	1739.913538	12.062042	0.693255
Switzerland	1081.522710	2054.765583	24.904831	1.212052
Armenia	991.166192	3204.351448	47.773156	1.490884
Liechtenstein	990.150607	1581.635312	7.816978	0.494234
France	829.924001	2188.285199	55.862393	2.552793
Netherlands	762.410353	2127.713990	43.125389	2.026841
Croatia	654.695521	1291.874926	14.572231	1.127991
Georgia	598.384392	1065.337391	8.556927	0.803213
Slovakia	571.221929	1134.389435	4.018038	0.354203
Spain	567.244732	2643.320651	77.245997	2.922309
Guam	560.088466	2805.224304	47.221973	1.683358
Poland	558.905145	1041.481995	15.471596	1.485537
Montenegro	554.500130	3087.521015	51.431896	1.665799
Austria	537.986347	1289.907465	12.812155	0.993262
Bosnia_and_Herzegovina	533.293265	1583.430223	38.776152	2.448870

Calculamos la correlación entre las variables

In [18]:
```
df_clustering.corr()
```

Out[18]:

	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID
cum14_casos_100k_ultimo_dia	1.000000	0.670030	0.501746	-0.086904
casos_100k	0.670030	1.000000	0.684265	-0.094868
muertes_100k	0.501746	0.684265	1.000000	0.233777
indice_mortalidad_COVID	-0.086904	-0.094868	0.233777	1.000000

De la tabla de correlaciones podemos obtener varias conclusiones:

- En el caso de los países que han tenido casos por cada 100k habitantes tienen un índice de correlación alto (68,4%) con los casos en los últimos 14 días.
- En cambio la relación con las muertes es baja (51,5%)
- No se ve una correlación fuerte entre las variables

Para llevar a cabo la clusterización haremos uso del algoritmo de clasificación K-Means

In [19]:
```
#Importamos K-means
from sklearn.cluster import KMeans
```

Se procede a preparar los datos para poder llevar a cabo la aplicación del algoritmo

Primero se comprobará que no haya datos nulos

In [20]:
```
df_clustering.isnull().sum().sort_values(ascending=False)
```

Out[20]:
```
cum14_casos_100k_ultimo_dia    3
muertes_100k                   2
casos_100k                     2
indice_mortalidad_COVID        0
dtype: int64
```

Borramos los datos nulos para evitar interferencias con los análisis

In [21]:
```
df_clustering = df_clustering.dropna()
```

Normalizamos los datospara que las diferentes unidades de medida que tienen nuestras variables esten a la misma escala y no interfieran con el modelo

In [22]:
```
from sklearn.preprocessing import StandardScaler, normalize
scaler = StandardScaler()
scaled_df = scaler.fit_transform(df_clustering)

normalized_df = normalize(scaled_df)
```

In [23]:
```
# Convertimos la matriz normalizada en un DataFrame
normalized_df = pd.DataFrame(normalized_df, columns = df_clustering.columns)
```

In [24]:
```
normalized_df.head(10)
```

Out[24]:

	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID
0	0.747726	0.392394	0.534849	0.029490
1	0.626086	0.637425	0.448146	-0.029527
2	0.892077	0.418168	0.150817	-0.081171
3	0.875089	0.459521	0.099628	-0.114604
4	0.899371	0.397668	-0.058030	-0.172116
5	0.951060	0.248380	-0.049426	-0.177059
6	0.929538	0.330602	0.120212	-0.110500
7	0.732721	0.568761	0.367590	-0.067145
8	0.941736	0.223898	-0.117113	-0.222008
9	0.723073	0.394258	0.564504	0.055333

Modelo K-means

A la hora de llevar a cabo el modelo de clusterización mediante el algoritmo K-means deberemos prestar atención a los siguientes parámetros:

- Determinar correctamente el valor k (número de clusters).
- Inicializar correctamente los clusters

Para determinar el número de clústers correcto se procede a utilizar el método del codo. Este método lo que hace es calcular Kmeans para distintos valores de k y quedarse con el que el error sea mínimo. En este caso utilizaremos de error la variable 'inertia'que mediará el desajuste entre los datos y los clusters.

In [25]:
```
desajuste = []
for i in range (1, 16):
    km = KMeans(n_clusters=i, random_state=0)
    km.fit(normalized_df)
    desajuste.append(km.inertia_)

plt.figure(figsize =(6, 3))
plt.plot(range(1, 16), desajuste, marker='o')
plt.xlabel('k')
plt.ylabel('desajuste')
plt.show()
```

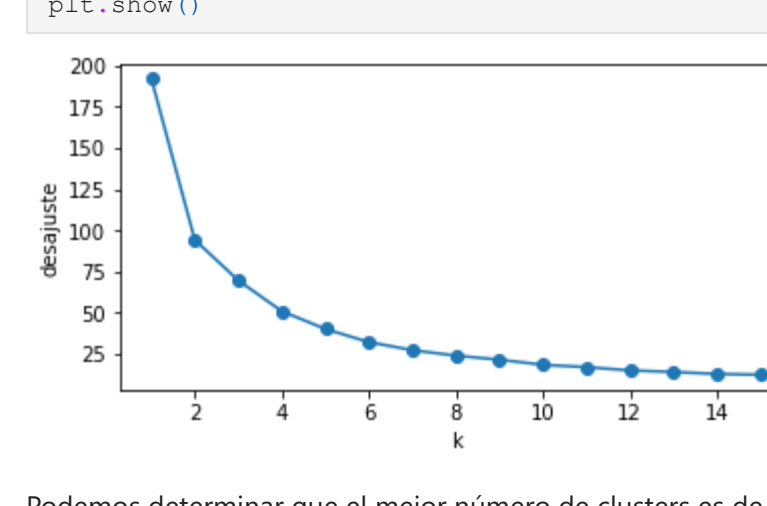

Podemos determinar que el mejor número de clusters es de 4 a 6. Si agregamos mas clusters no obtendremos ninguna ganancia

In [26]:
```
n_clusters = 4
km = KMeans(n_clusters=n_clusters)
km.fit(normalized_df)
```

Out[26]: KMeans(n_clusters=4)

In [27]:
```
# Agregamos la etiqueta de cada uno de los clusters al dataframe
df_clustering['Cluster'] = km.predict(normalized_df)
df_clustering.head(10)
```

Out[27]:

countriesAndTerritories	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID	Cluster
Belgium	1753.181152	3904.318958	103.513424	2.651254	1
Andorra	1660.606220	6416.634942	98.454914	1.534370	1
Czechia	1586.264531	3294.859997	34.310503	1.041334	3
Luxembourg	1337.853115	3111.449208	26.063131	0.837652	3
French_Polynesia	1240.668135	2600.211254	10.383658	0.399339	3
Slovenia	1082.460157	1739.913538	12.062042	0.693255	3
Switzerland	1081.522710	2054.765583	24.904831	1.212052	3
Armenia	991.166192	3204.351448	47.773156	1.490884	3
Liechtenstein	990.150607	1581.635312	7.816978	0.494234	3
France	829.924001	2188.285199	55.862393	2.552793	1

In [28]:
```
# Cálculo promedio de cada uno de los clusters
df_clustering.groupby('Cluster').mean()
```

Out[28]:

Cluster	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID
0	18.390733	224.190826	8.525944	4.933403
1	326.885842	2125.823387	50.884495	2.849107
2	24.277771	216.766154	2.617328	1.208944
3	483.378152	1653.094930	13.593248	0.984061

In [29]:
```
# Se crea un Headmap para visualizar los datos de los clusters

cm = sns.light_palette('red', as_cmap=True)
df_clustering.groupby('Cluster').mean().style.background_gradient(cmap='Reds')
```

Out[29]:

Cluster	cum14_casos_100k_ultimo_dia	casos_100k	muertes_100k	indice_mortalidad_COVID
0	18.390733	224.190826	8.525944	4.933403
1	326.885842	2125.823387	50.884495	2.849107
2	24.277771	216.766154	2.617328	1.208944
3	483.378152	1653.094930	13.593248	0.984061

Con el Headmap podemos observar las diferencias presentes entre cada uno de los clusters:

1- Cluster 0 = un índice de mortalidad muy elevado sin haber tenido gran cantidad de casos de Covid. Los países pertenecientes a este clúster es posible que hay una falta de datos de recuento de positivos en COVID.

2- Cluster 1 = gran incidencia de casos, tanto totales como en los últimos 14 días, con un índice de mortalidad medio.

3- Cluster 2 = baja incidencia de Covid, con índices bajos de contagios y baja mortalidad. Existe una fuerte correlación.

4- Cluster 3 = gran cantidad de casos, con índices de mortalidad bajos.

Veamos la clasificación para algunos países

In [30]:
```
df_clustering.loc['Spain']
```

Out[30]:
```
cum14_casos_100k_ultimo_dia     567.244732
casos_100k                     2643.320651
muertes_100k                     77.245997
indice_mortalidad_COVID           2.922309
Cluster                           1.000000
Name: Spain, dtype: float64
```

In [31]:
```
df_clustering.loc['France']
```

Out[31]:
```
cum14_casos_100k_ultimo_dia     829.924001
casos_100k                     2188.285199
muertes_100k                     55.862393
indice_mortalidad_COVID           2.552793
Cluster                           1.000000
Name: France, dtype: float64
```

In [32]:
```
df_clustering.loc['Japan']
```

Out[32]:
```
cum14_casos_100k_ultimo_dia     6.937553
casos_100k                     80.424909
muertes_100k                    1.403118
indice_mortalidad_COVID         1.740304
Cluster                         2.000000
Name: Japan, dtype: float64
```

In [33]:
```
df_clustering.loc['Belgium']
```

Out[33]:
```
cum14_casos_100k_ultimo_dia    1753.181152
casos_100k                     3904.318958
muertes_100k                    103.513424
indice_mortalidad_COVID           2.651254
Cluster                           1.000000
Name: Belgium, dtype: float64
```

Análisis en detalle de los 25 países con mayor número de contagio

In [34]:
```
top25country = df[['countriesAndTerritories', 'cases']].\
        groupby('countriesAndTerritories').sum().\
        sort_values('cases', ascending=False).\
        nlargest(25, 'cases')
top25country
```

Out[34]:

countriesAndTerritories	cases
United_States_of_America	9291245
India	8267623
Brazil	5554206
Russia	1655038
France	1466433
Spain	1240697
Argentina	1183118
Colombia	1093256
United_Kingdom	1053864
Mexico	933155
Peru	906545
Italy	731588
South_Africa	727595
Iran	628780
Germany	560379
Chile	513188
Iraq	478701
Belgium	447260
Indonesia	415402
Bangladesh	410988
Ukraine	402194
Poland	395480
Philippines	385400
Turkey	379775
Netherlands	367715

Se realizará una matriz de gráficos para ver la evolución de la tasa de casos de los últimos 14 días por 100k habitantes.

In [35]:
```
fig, axes = plt.subplots(nrows=5, ncols=5, sharex=True, sharey=True, figsize= (15,15))
axes_list = [item for sublist in axes for item in sublist]

for countryname in top25country.index.values:
    ax = axes_list.pop(0)
    selection=df[df['countriesAndTerritories']==countryname]['Cum14_cases_100k']
    selection.plot(x=countryname, y='Cum14_cases_100k', label=countryname, ax=ax, legend=False)
    ax.set_title(countryname)
    ax.tick_params(
        which='both',
        bottom='off',
        left='off',
        right='off',
        top='off'
    )
    ax.grid(linewidth=0.20)
    ax.set_ylim((0, 900))
    ax.spines['left'].set_visible(False)
    ax.spines['top'].set_visible(False)
    ax.spines['right'].set_visible(False)
    ax.spines['bottom'].set_visible(False)

#borramos todo lo que no usamos en el plot

for ax in axes_list:
    ax.remove()
```

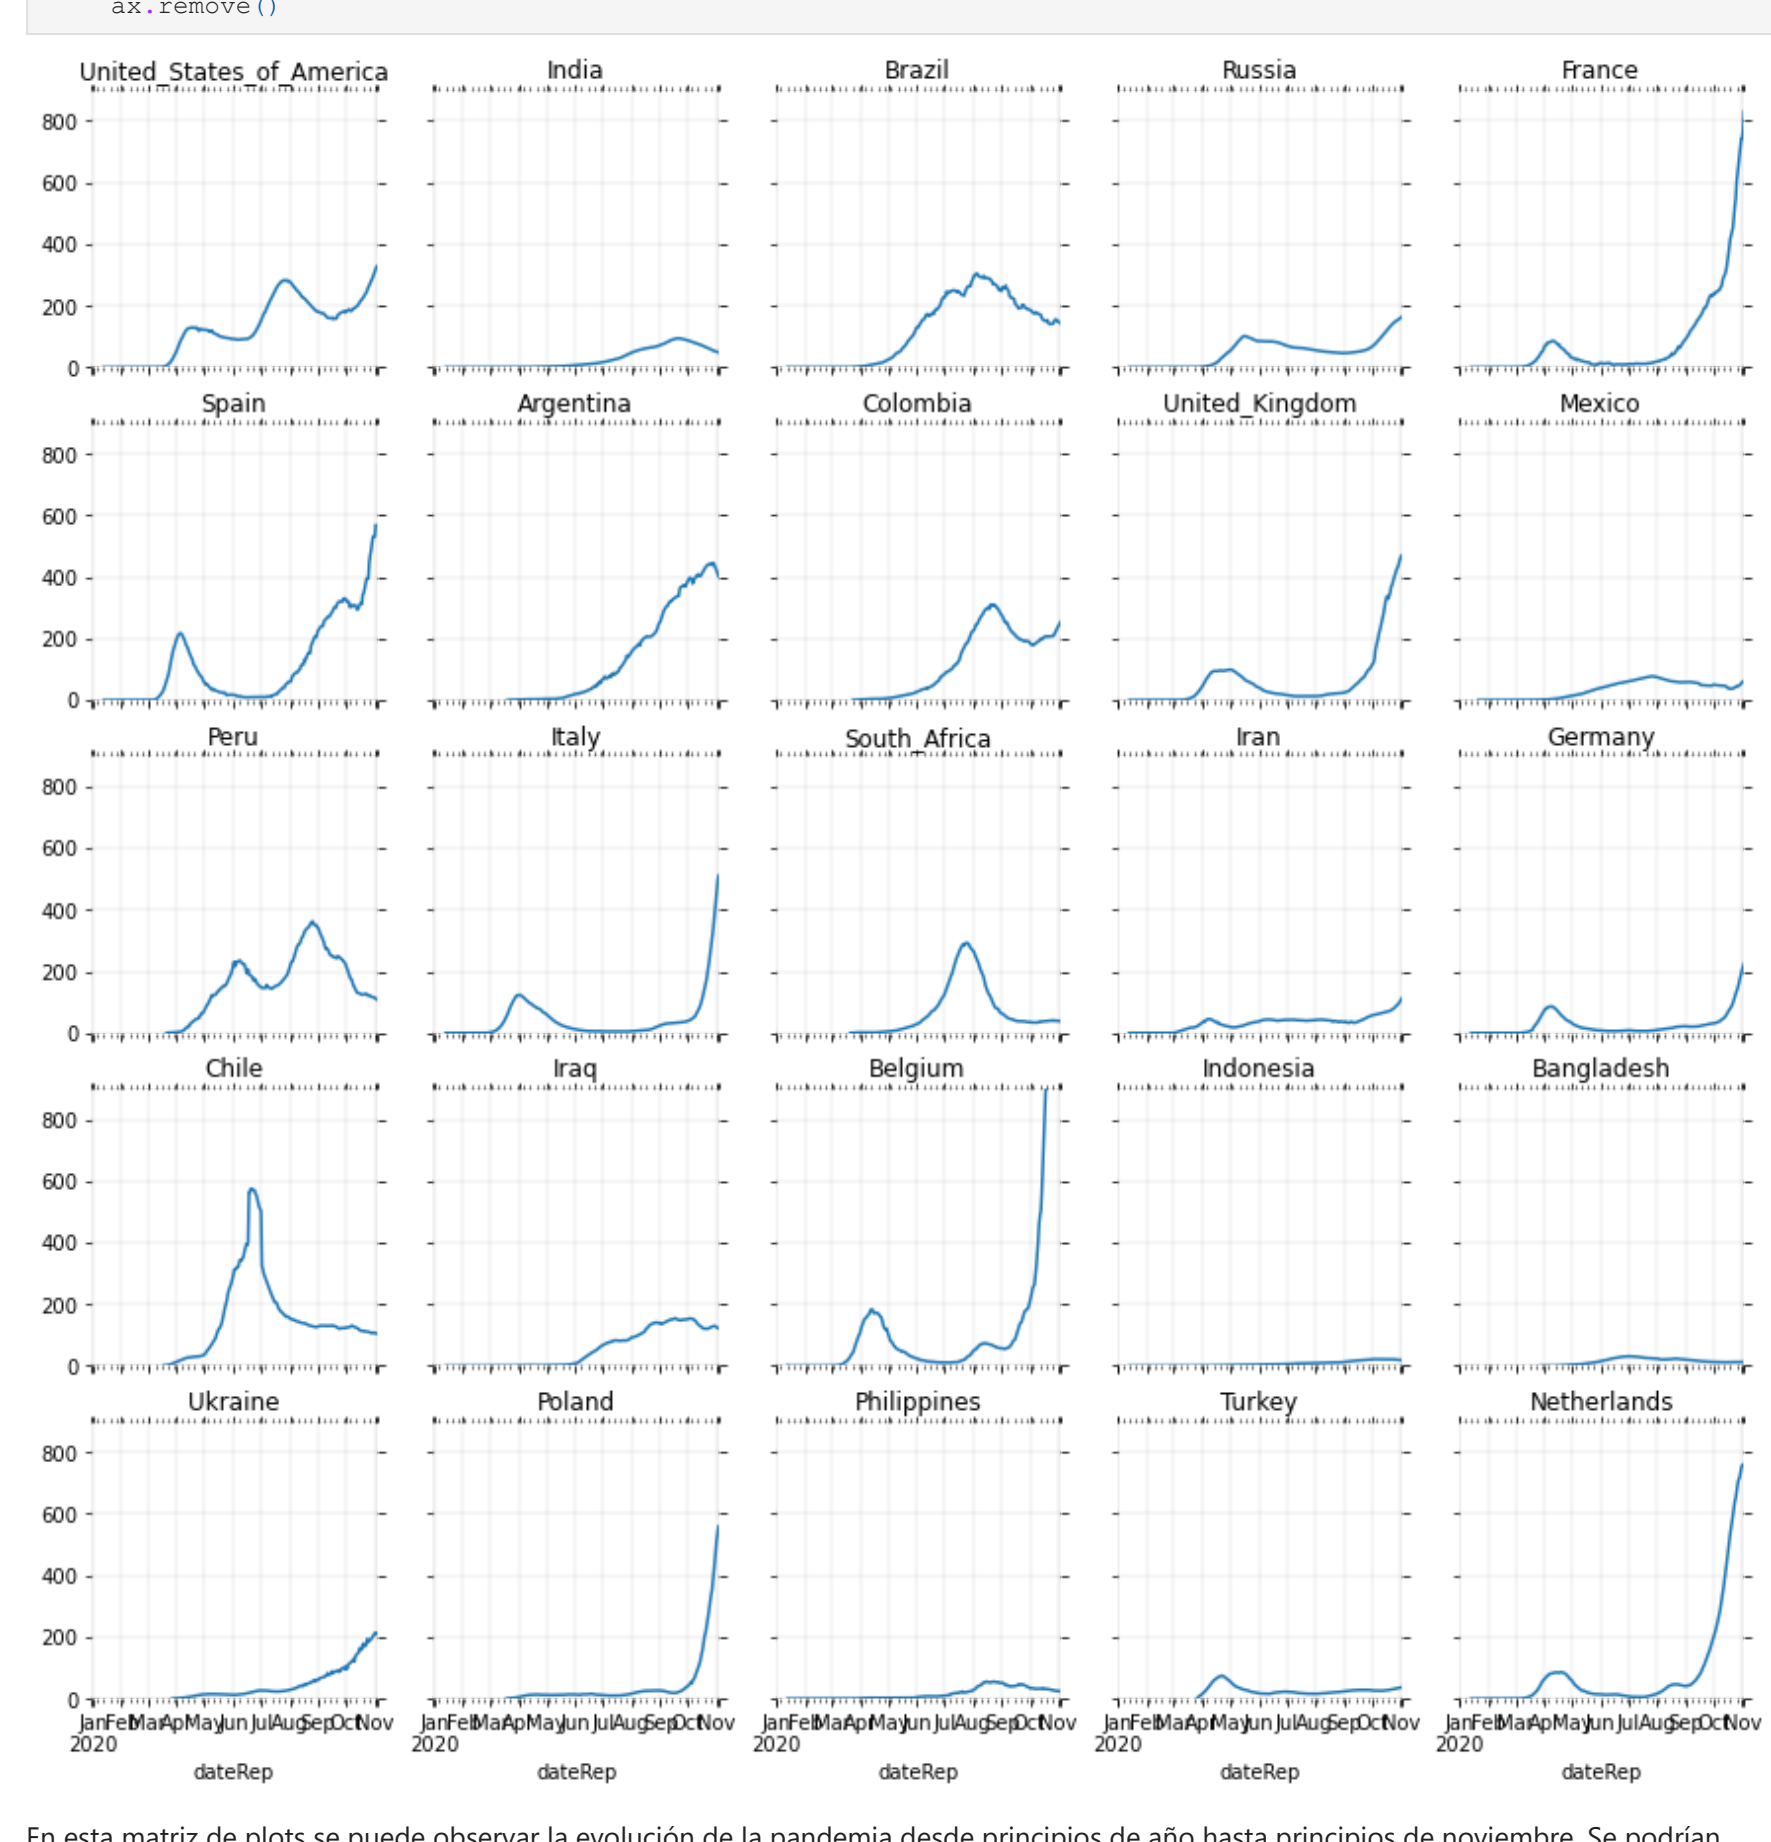

En esta matriz de plots se puede observar la evolución de la pandemia desde principios de año hasta principios de noviembre. Se podrían analizar las diferentes políticas aplicadas en cada uno de los países y su efecto en los datos acumulados.

Realizamos el estudio de la evolución de los casos en España

In [36]:
```
df[df['countriesAndTerritories']=='Spain']['cases'].plot()
```

Out[36]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcd53e72b0>`

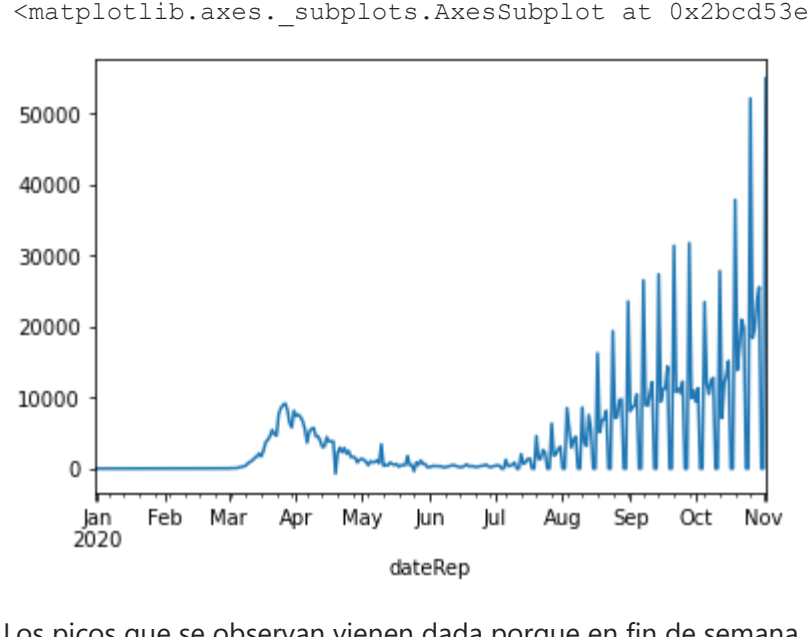

Los picos que se observan vienen dada porque en fin de semana no se dan datos y a principios de semana se observa el crecimieto exponencial de los datos acumulados de fin de semana.

In [37]:
```
# Ahora miramos la evolución de las muertes en España
df[df['countriesAndTerritories']=='Spain']['deaths'].plot()
```

Out[37]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcd5f583a0>`

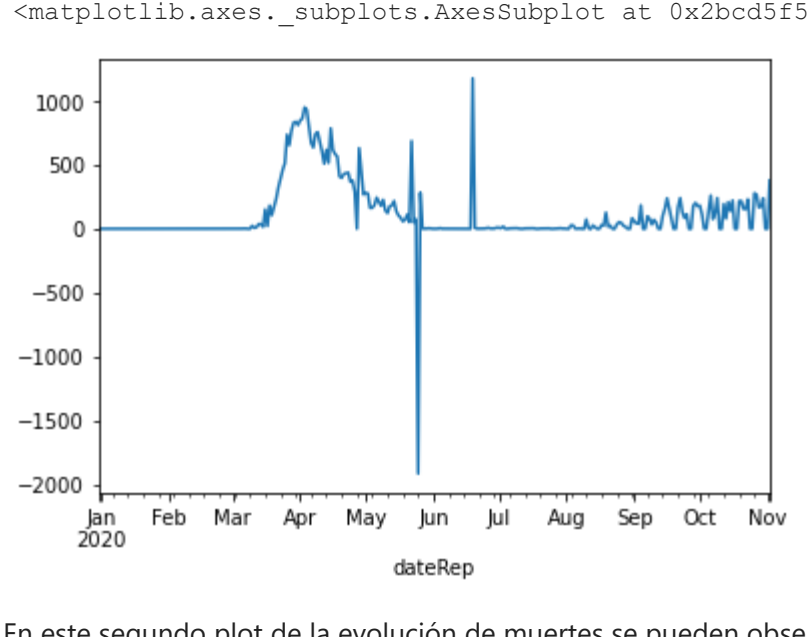

En este segundo plot de la evolución de muertes se pueden observar dos picos; uno de ellos positivo y otro negativo. Esto hace referencia a recuentos de muertes por Covid no contabilizadas en su momento de hecho.

In [38]:
```
df[df['countriesAndTerritories']=='Spain']['deaths'].rolling(window=7).mean().plot()
```

Out[38]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcd601eb20>`

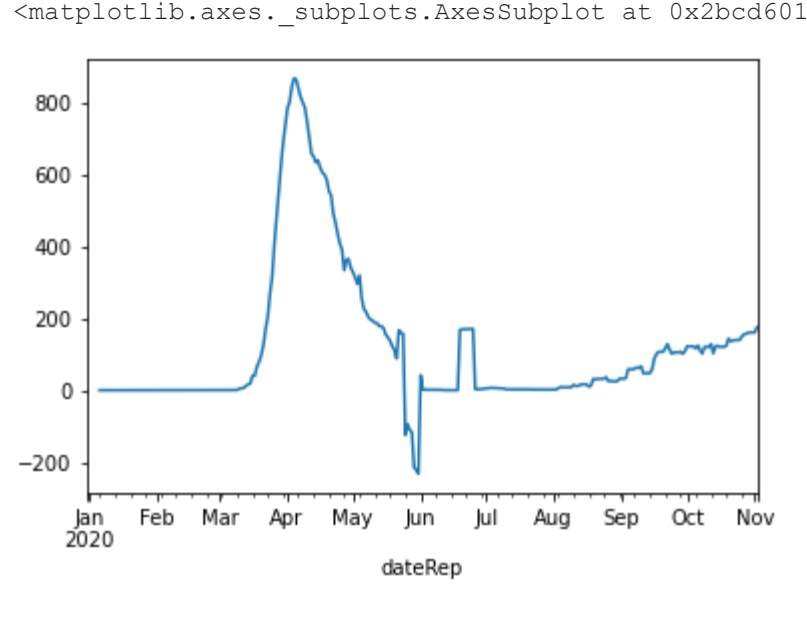

Como ha evolucionado el índice de mortalidad en España

In [41]:
```
#Se crea un dataframe donde queden representados los fallecimientos y los contagios.

df_fallecimientos = df[df['countriesAndTerritories'] == 'Spain'][['deaths','cases']]
```

In [42]:
```
df_fallecimientos.plot(subplots=True)
```

Out[42]:
```
array([<matplotlib.axes._subplots.AxesSubplot object at 0x000002BCD612D910>,
       <matplotlib.axes._subplots.AxesSubplot object at 0x000002BCD618FC70>],
      dtype=object)
```

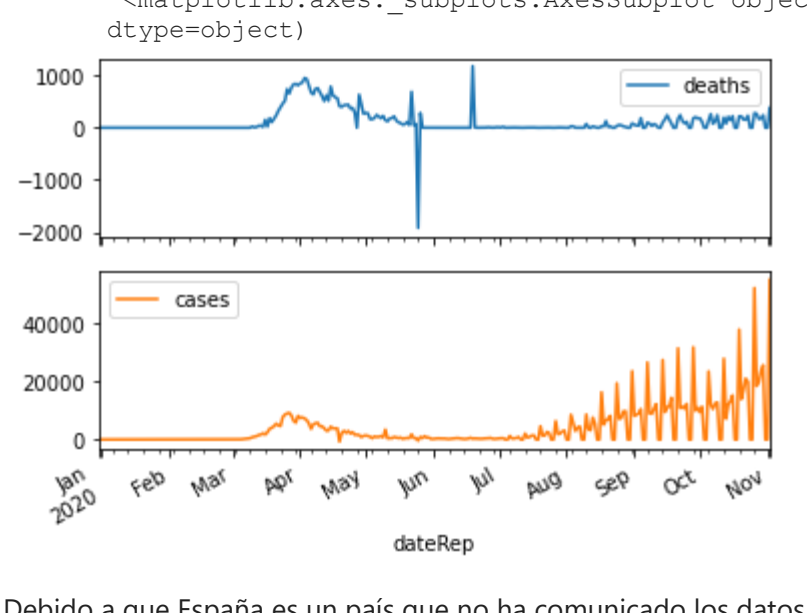

Debido a que España es un país que no ha comunicado los datos de muertes y casos de forma diaria, ya que durante el fin de semana no ha comunicado ningún caso o fallecimiento, calculamos la media móvil para interpretar mejor los gráficos.

In [43]:
```
df_fallecimientos['deaths_mm7'] = df_fallecimientos['deaths'].rolling(window=7).mean()
```

In [44]:
```
df_fallecimientos['cases_mm7'] = df_fallecimientos['cases'].rolling(window=7).mean()
```

In [46]:
```
df_fallecimientos[['cases_mm7','cases']].plot()
```

Out[46]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcd4fd31f0>`

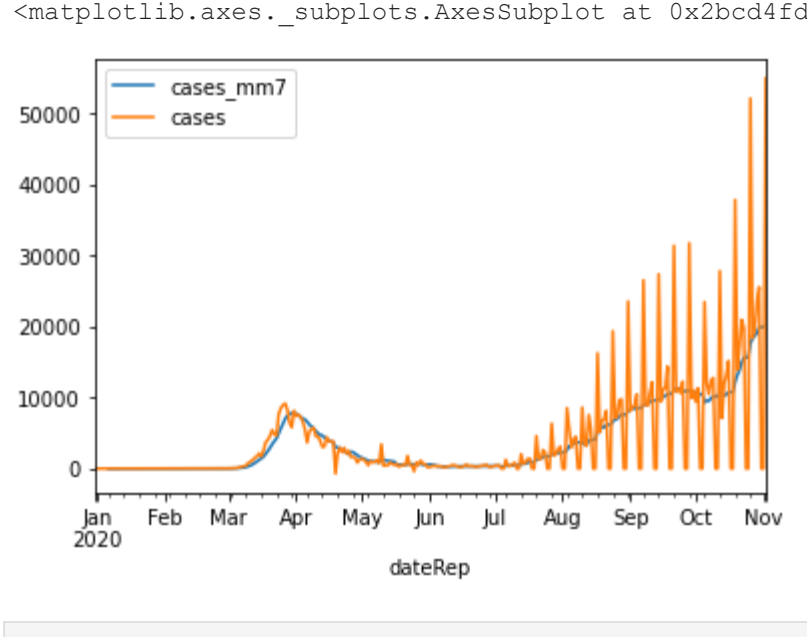

In [48]:
```
df_fallecimientos[['deaths_mm7','deaths']].plot(subplots=True)
```

Out[48]:
```
array([<matplotlib.axes._subplots.AxesSubplot object at 0x000002BCDBA31B50>,
       <matplotlib.axes._subplots.AxesSubplot object at 0x000002BCDBA77880>],
      dtype=object)
```

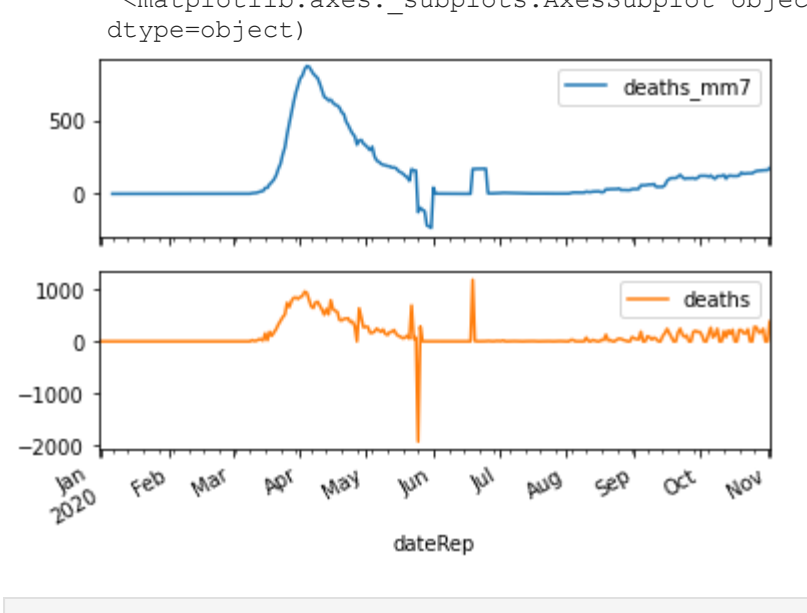

In [49]:
```
df_fallecimientos['indice_mortalidad'] = df_fallecimientos['deaths_mm7']/df_fallecimientos['cases_mm7']*100
```

In [50]:
```
df_fallecimientos['indice_mortalidad'].plot()
```

Out[50]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcdb35ad30>`

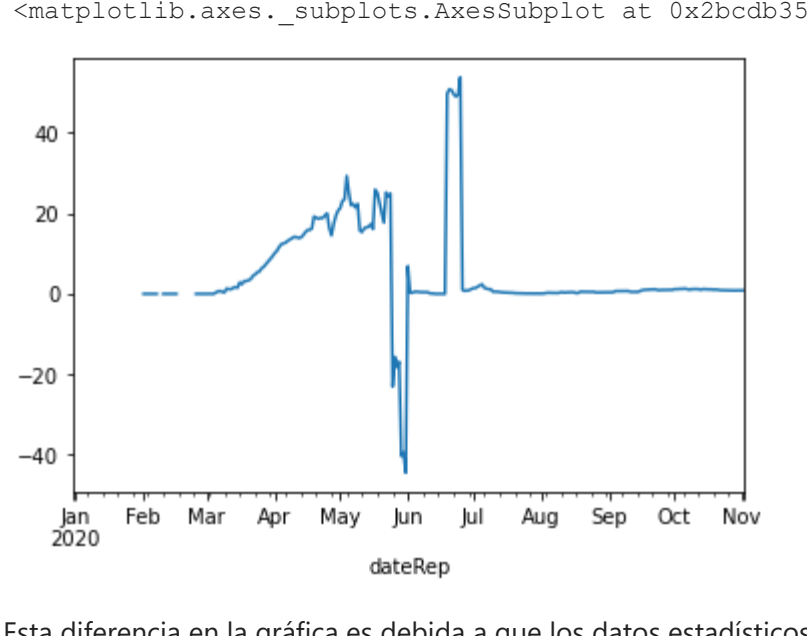

Esta diferencia en la gráfica es debida a que los datos estadísticos de la pandemia no se han tratado de la forma correcta. Otro factor que influye en los datos es la evolución de los protocolos seguidos para la detección de casos, ya que han ido variando a lo largo del tiempo.

Se procede a dividir los datos en las dos oleadas de la pandemia, y así eliminar la parte donde España realizó el ajuste en las muertes

In [53]:
```
df_fallecimientos.loc[:'2020-05-15']['indice_mortalidad'].plot()
```

Out[53]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcdb5befd0>`

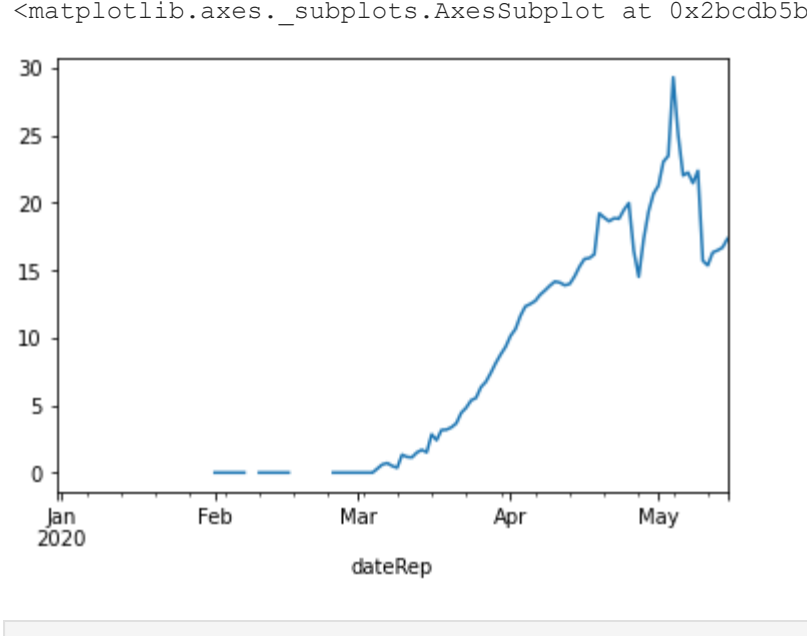

In [54]:
```
df_fallecimientos['indice_mortalidad'].iloc[190:].plot()
```

Out[54]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcdb547760>`

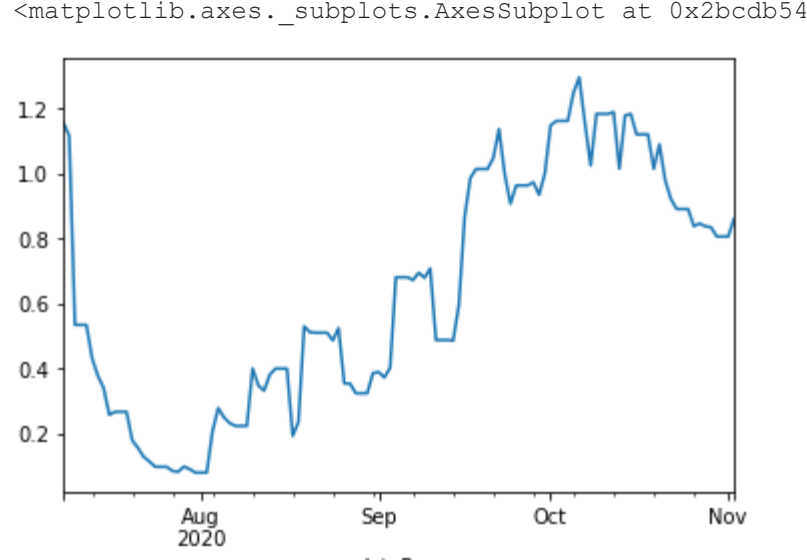

En este último gráfico podemos observar la evolución del índice de mortalidad durante la segunda ola de la pandemia. Se puede observar que un índice de mortalidad acorde a la realidad, ya que no existen ajustes en los datos, como si ocurre durante la primera ola, donde no se apuntaban todos los casos reales, ya que no se hacian pruebas PCR.

In [55]:
```
df_fallecimientos['indice_mortalidad_2'] = df_fallecimientos['deaths_mm7']\
                                            /df_fallecimientos['cases_mm7'].shift(14)*100
```

In [57]:
```
df_fallecimientos.loc['2020-04-1':'2020-05-15']['indice_mortalidad_2'].plot()
```

Out[57]: `<matplotlib.axes._subplots.AxesSubplot at 0x2bcdd29e970>`

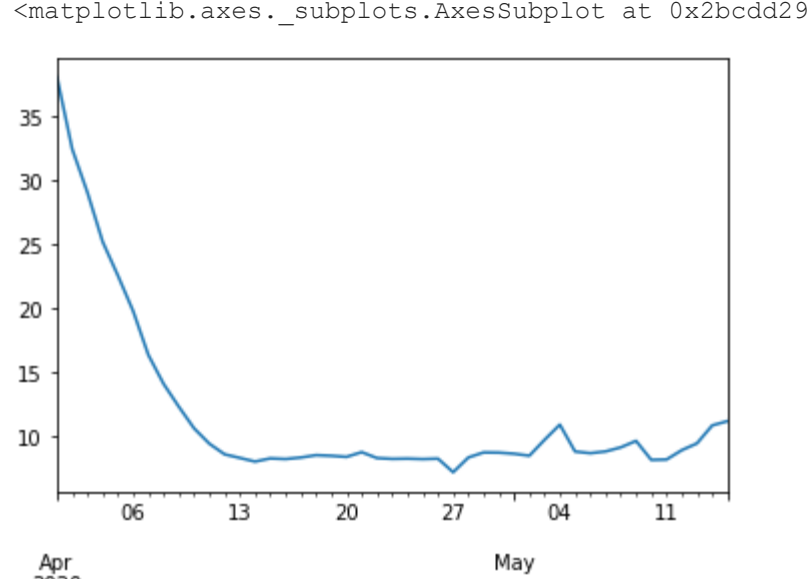

Aquí podemos observar, como después de los ajustes en los datos de casos y muertos, el índice de mortalidad se va ajustando a dats reales. También coincidió con el cambio en los protocolos de detección de casos mediantes las pruebas PCR.

In [60]:
```
df_fallecimientos['indice_mortalidad'].loc['2020-08-01':].plot();
```

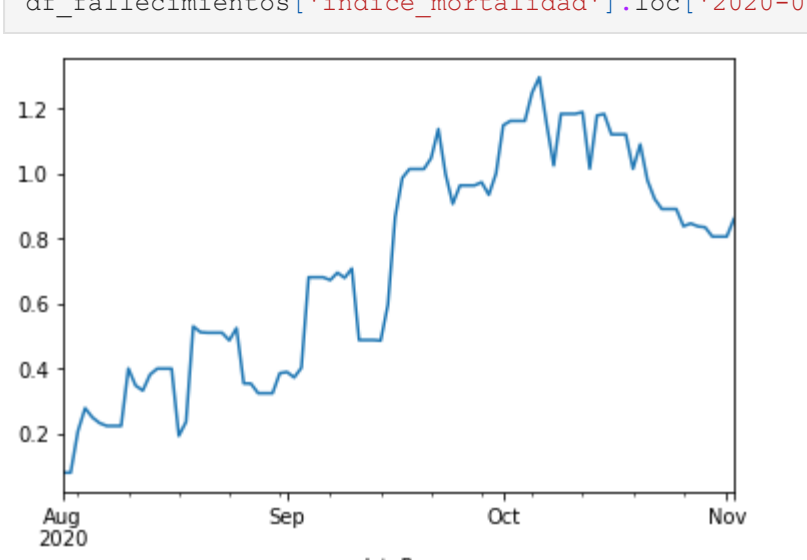

En este último gráfico se observa la evolución del índice de mortalidad a lo largo de la segunda ola. Se puede determinar que el índice real se mueve entre el 0,2% y un 1% (dato muy elevado para una pandemia de esta tipología.

Modelo de predicción

Se utilizará un modelo de regresión SVR con el objetivo de determinar la predicción de la evolución futura de la pandemia con los datos que tenemos hasta hoy. Y como variable utilizamos el número de días que han transcurrido desde el inicio de la pandemia

In [61]:
```
#Se utiliza la variable de media movil semanal de casos.
data = pd.DataFrame(df_fallecimientos['cases_mm7'])
```

In [69]:
```
#El inicio de la pandemia la indico cuando llegamos al caso 100
fecha100 = data[data.cases_mm7.cumsum()>100].index.min()
fecha100
```

Out[69]: `Timestamp('2020-03-03 00:00:00')`

In [70]:
```
data = data[fecha100:]
data
```

Out[70]:

dateRep	cases_mm7	n-dia
2020-03-03	27.000000	63
2020-03-04	36.857143	64
2020-03-05	47.285714	65
2020-03-06	70.857143	66
2020-03-07	101.428571	67
...	...	...
2020-10-29	19114.571429	303
2020-10-30	19935.142857	304
2020-10-31	19935.142857	305
2020-11-01	19935.142857	306
2020-11-02	20339.571429	307

245 rows × 2 columns

In [73]:
```
data['n-dia']=0
for i in range(data.shape[0]):
    data['n-dia'][i]=i

data
```

Out[73]:

dateRep	cases_mm7	n-dia
2020-03-03	27.000000	0
2020-03-04	36.857143	1
2020-03-05	47.285714	2
2020-03-06	70.857143	3
2020-03-07	101.428571	4
...	...	...
2020-10-29	19114.571429	240
2020-10-30	19935.142857	241
2020-10-31	19935.142857	242
2020-11-01	19935.142857	243
2020-11-02	20339.571429	244

245 rows × 2 columns

Observando los datos, desarrollamos el modelo solo a partir del 1 de mayo como fecha inicio

In [76]:
```
data = data.loc['2020-05-01':]
data
```

Out[76]:

dateRep	cases_mm7	n-dia
2020-05-01	1543.857143	59
2020-05-02	1362.142857	60
2020-05-03	1261.285714	61
2020-05-04	1090.714286	62
2020-05-05	1021.285714	63
...	...	...
2020-10-29	19114.571429	240
2020-10-30	19935.142857	241
2020-10-31	19935.142857	242
2020-11-01	19935.142857	243
2020-11-02	20339.571429	244

186 rows × 2 columns

In [77]:
```
x = data['n-dia'].values

x
```

Out[77]:
```
array([ 59,  60,  61,  62,  63,  64,  65,  66,  67,  68,  69,  70,  71,
        72,  73,  74,  75,  76,  77,  78,  79,  80,  81,  82,  83,  84,
        85,  86,  87,  88,  89,  90,  91,  92,  93,  94,  95,  96,  97,
        98,  99, 100, 101, 102, 103, 104, 105, 106, 107, 108, 109, 110,
       111, 112, 113, 114, 115, 116, 117, 118, 119, 120, 121, 122, 123,
       124, 125, 126, 127, 128, 129, 130, 131, 132, 133, 134, 135, 136,
       137, 138, 139, 140, 141, 142, 143, 144, 145, 146, 147, 148, 149,
       150, 151, 152, 153, 154, 155, 156, 157, 158, 159, 160, 161, 162,
       163, 164, 165, 166, 167, 168, 169, 170, 171, 172, 173, 174, 175,
       176, 177, 178, 179, 180, 181, 182, 183, 184, 185, 186, 187, 188,
       189, 190, 191, 192, 193, 194, 195, 196, 197, 198, 199, 200, 201,
       202, 203, 204, 205, 206, 207, 208, 209, 210, 211, 212, 213, 214,
       215, 216, 217, 218, 219, 220, 221, 222, 223, 224, 225, 226, 227,
       228, 229, 230, 231, 232, 233, 234, 235, 236, 237, 238, 239, 240,
       241, 242, 243, 244], dtype=int64)
```

In [79]:
```
y = data['cases_mm7'].values

y
```

Out[79]:
```
array([ 1543.85714286,  1362.14285714,  1261.28571429,  1090.71428571,
        1021.28571429,  1026.        ,   980.28571429,   949.71428571,
         879.57142857,  1234.        ,  1223.57142857,  1144.        ,
        1081.        ,  1070.71428571,   995.        ,   962.42857143,
         567.57142857,   548.        ,   540.71428571,   552.        ,
         499.57142857,   663.        ,   656.        ,   631.71428571,
         542.        ,   603.14285714,   602.        ,   695.57142857,
         534.28571429,   562.57142857,   522.42857143,   605.42857143,
         524.71428571,   508.14285714,   393.42857143,   344.85714286,
         297.42857143,   303.        ,   297.        ,   290.57142857,
         279.14285714,   292.42857143,   318.71428571,   327.85714286,
         339.71428571,   341.71428571,   337.42857143,   343.28571429,
         365.85714286,   338.        ,   333.28571429,   334.85714286,
         342.14285714,   346.28571429,   343.28571429,   316.85714286,
         332.85714286,   361.57142857,   356.85714286,   352.28571429,
         359.85714286,   367.57142857,   373.85714286,   377.14285714,
         296.57142857,   253.57142857,   402.71428571,   408.42857143,
         407.71428571,   421.85714286,   480.42857143,   480.42857143,
         480.42857143,   594.85714286,   641.28571429,   711.57142857,
         828.42857143,   906.71428571,   906.71428571,   906.71428571,
        1269.        ,  1367.85714286,  1436.71428571,  1615.85714286,
        1738.        ,  1738.        ,  1738.        ,  1992.28571429,
        2059.42857143,  2155.71428571,  2180.57142857,  2300.14285714,
        2300.14285714,  2300.14285714,  2610.28571429,  3172.        ,
        3303.71428571,  3489.28571429,  3691.42857143,  3691.42857143,
        3691.42857143,  3703.71428571,  3399.71428571,  3431.        ,
        3925.57142857,  4064.42857143,  4064.42857143,  4064.42857143,
        5157.42857143,  5369.14285714,  5869.        ,  5796.        ,
        6177.28571429,  6177.28571429,  6177.28571429,  6622.        ,
        6908.14285714,  6997.42857143,  7371.57142857,  7604.57142857,
        7604.57142857,  7604.57142857,  8203.14285714,  8345.71428571,
        8529.28571429,  8429.42857143,  8529.        ,  8529.        ,
        8529.        ,  8955.85714286,  9077.14285714,  9117.85714286,
        9375.71428571,  9619.57142857,  9619.57142857,  9619.57142857,
        9740.14285714,  9807.71428571, 10140.14285714, 10215.42857143,
       10530.57142857, 10530.57142857, 10530.57142857, 11105.42857143,
       11300.        , 11313.71428571, 11222.57142857, 10920.14285714,
       10920.14285714, 10920.14285714, 10971.14285714, 10843.57142857,
       10804.57142857, 10628.28571429, 10493.        , 10493.        ,
       10493.        ,  9306.57142857,  9605.42857143,  9530.42857143,
        9959.57142857, 10168.57142857, 10168.57142857, 10168.57142857,
       10793.71428571, 10096.57142857, 10307.85714286, 10435.71428571,
       10778.28571429, 10778.28571429, 10778.28571429, 12211.57142857,
       13176.57142857, 13891.28571429, 14986.71428571, 15653.14285714,
       15653.14285714, 15653.14285714, 17695.85714286, 18345.14285714,
       18744.        , 19114.57142857, 19935.14285714, 19935.14285714,
       19935.14285714, 20339.57142857])
```

In [81]:
```
#Normalizo los datos de la variable

x = x.reshape(-1,1)
y = y.reshape(-1,1)
```

In [82]:
```
from sklearn.preprocessing import StandardScaler
sc_x = StandardScaler()
sc_y = StandardScaler()

x = sc_x.fit_transform(x)
y = sc_y.fit_transform(y)
```

In [111]:
```
from sklearn.svm import SVR

regressor = SVR(kernel = 'rbf', C= 100, gamma= .1, epsilon= .1)
regressor.fit(x, y)
```

Out[111]: `SVR(C=100, gamma=0.1)`

In [160]:
```
x_grid = np.arange(min(x), max(x)*5, 0.1)
x_grid = x_grid.reshape((len(x_grid),1))
prediccion = regressor.predict(x_grid)
prediccion_t = np.rint(sc_y.inverse_transform(prediccion))
x_t = sc_x.inverse_transform(x)
y_t = sc_y.inverse_transform(y)
plt.scatter(x_t, y_t, color= 'red')
x_grid_t = sc_x.inverse_transform(x_grid)
plt.plot(x_grid_t, prediccion_t, color="green")
plt.title('Evolución casos Covid-19 España')
plt.ylabel('Número de casos')
plt.xlabel('Días desde inicio de la pandemia')
plt.show()
```

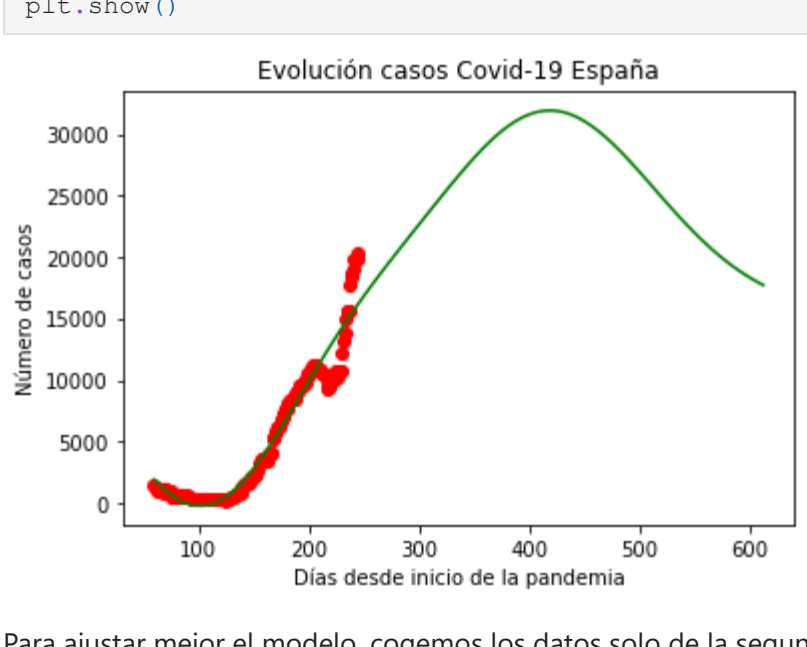

Para ajustar mejor el modelo, cogemos los datos solo de la segunda ola de la pandemia y así observamos la previsión de evolución.

Previsión máximo pandemia

In [164]:
```
maximo = np.max(prediccion_t)
maximo
```

Out[164]: `31951.0`

In [165]:
```
# El día que alcanzaremos el máximo?

dias_maximo = np.rint(x_grid_t[np.where(prediccion_t == maximo)][0,0])
dias_maximo
```

Out[165]: `419.0`

In [166]:
```
fecha100 + datetime.timedelta(days=dias_maximo)
```

Out[166]: `Timestamp('2021-04-26 00:00:00')`

Con los datos extraidos del modelo de predicción podemos indicar que el máximo de casos se daran el próximo día 26 de abril de 2021 alcanzando los 31951 casos.

Se debe tener en cuenta que se trata de una predicción y conociendo que los datos estadísticos de la primera ola fueron incorrectos debido a la falta de ellos o recuentos tardíos