

[]:	1 1 2 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0	enlt.pay	R Y E	VALU	UAR	UN	CLA est split	SIFIC	ADC			009	ST (E	EN L	.OC	AL
[]:	X_train.s (22500, 33) X_test.sh (7500, 33) !pip inst Requirement Requirement # Entrena import xg model = x model.fit	ape all xgb at alrea at alrea r un mo boost a gb.XGBC	ady satis ady satis ady satis adelo de .s xgb	sfied: sfied: regresi	scipy i numpy i	n /usr, n /usr, XGBoos	/local/l /local/l	ib/python ib/python	3.6/dis 3.6/dis	t-pack	cages cages	from >	gboost) (1.1	9.5)	ors =
	<pre>from skle y_pred = y_pred array([1, from skle print("Ac</pre>	col lea min nth reg sil arn.met model.p	sample_karning_ran_child_varead=Norg_alpha=(content) rics imported (X	opynode=1 ate=0.1, weight=1 ne, obje), reg_1 e, subse port acc (_test) o, 0])	1, cols, max_d 1, miss ective= lambda= ample=1 curacy_	ample_lelta_sting=Non'reg:scil, scal, verboscore	cep=0, mode, n_es,	, gamma=0 ax_depth= timators= ror', ran eight=1,	, 5, 100, n_ dom_sta seed=No	jobs=1 te=0, ne,	L,					
		a en el usion_m ap(cm,	conjunt atrix(y_ annot= Tr	o de te pred, y	z_test)			0be0>								
(accura macro a veighted a	o 1 cy vy vy VY VY VY	0.84 0.67 0.75 0.80	0.9 0.3 0.6 0.8 S HI CH	11 f1- 95 36 65 32	0.89 0.47 0.82 0.68 0.80	588 161 750 750 750	TROS		XG	вос	OST	REA	\LIZ	AN	DC
[]:	•	subsamp colsamp max_dep ost imp = XGBC arn.mod idSearc	le': [0. le_bytre th': [3, cort XGBC lassified el_selecthCV(xgb_	6, 0.8, ee': [0. 4, 5] Classifi er(learn ttion im model,	1.0], 6, 0.8 # prof er ning_ra	# % de, 1.0], undidad	# % de d de cada , n_est:	mators=1	s para usadas	por d	cada ái	rbol				



[n []:	<pre># Boto3 es el kit de desarrollo de software (SDK) de Amazon Web Services (AWS) para Python import sagemaker import boto3 # Crear una sesión de sagemaker sagemaker_session = sagemaker.Session() # S3 Bucket y prefijo que queremos usar bucket = 'sagemaker-practical-1' prefix = 'XGBoost-Regressor' key = 'XGBoost-Regressor' # Los roles dan acceso de aprendizaje y al alojamiento a nuestros datos # Esto se especifica al abrir la instancia de sagemakers en "Crear un rol de IAM" role = sagemaker.get_execution_role()</pre>
[n []:	<pre>print(role) # leer los datos del archivo csv y luego cargar los datos en el depósito s3 import os with open('train.csv','rb') as f: # El siguiente código carga los datos en el bucket de S3 para acceder más tarde al entrenamiento boto3.Session().resource('s3').Bucket(bucket).Object(os.path.join(prefix, 'train', key)).upload_fileobj('s') # Ubicación de los datos de entrenamiento en s3 s3_train_data = 's3://{}/{}/{train/{}'.format(bucket, prefix, key) print('ubicación de datos de entrenamiento cargados: {}'.format(s3_train_data)) with open('validation.csv','rb') as f: # Código de carga los datos en el bucket de S3 para acceder más tarde al entrenamiento boto3.Session().resource('s3').Bucket(bucket).Object(os.path.join(prefix, 'validation', key)).upload_file</pre>
	<pre># Ubicación de los datos de validación en s3 s3_validation_data = 's3://{}/{}/validation/{}'.format(bucket, prefix, key) print('uploaded validation data location: {}'.format(s3_validation_data)) # Placeholder de salida en el bucket S3 para almacenar la salida output_location = 's3://{}/{}/output'.format(bucket, prefix) print('los artefactos de entrenamiento se cargarán en: {}'.format(output_location)) # Este código se usa para obtener el contenedor de entrenamiento de los algoritmos integrados de sagemaker # todo lo que tenemos que hacer es especificar el nombre del algoritmo que queremos usar # Obtengamos una referencia a la imagen del contenedor XGBoost from sagemaker.amazon.amazon_estimator import get_image_uri</pre>
[n []:	container = get_image_uri(boto3.Session().region_name, 'xgboost','0.90-2') # Latest version of XGboost # Especificar el tipo de instancia que nos gustaría usar para el entrenamiento. # ruta de salida y sesión de sagemaker en el Estimador. # También podemos especificar cuántas instancias nos gustaría utilizar para el entrenamiento # Recordemos que XGBoost funciona combinando un conjunto de modelos débiles para generar resultados precisos # Los modelos débiles son aleatorios para evitar el sobreajuste # num_round: el número de rondas para ejecutar el entrenamiento. # Alfa: Término de regularización L1 sobre pesos. Incrementar este valor hace que los modelos sean más conse: # colsample by tree: fracción de características que se usarán para entrenar cada árbol.
	<pre># eta: Reducción del tamaño del paso que se utiliza en las actualizaciones para evitar el sobreajuste. # Después de cada paso de boosting, el parámetro eta reduce los pesos de las funciones para hacer que el prod Xgboost_regressor1 = sagemaker.estimator.Estimator(container,</pre>
[n []:	<pre>objective = 'reg:linear',</pre>
	DESPLIEGUE EL MODELO PARA REALIZAR LA INFERENCIA # Implementar el modelo para realizar inferencias Xgboost_regressor = Xgboost_regressor1.deploy(initial_instance_count = 1, instance_type = 'ml.m5.2xlarge') IIIIIIIIIIIIIIIIIIIIIIIIIIIIIIIIIII
[n []:	El serializador acepta un solo argumento, los datos de entrada, y devuelve una secuencia de bytes en el conte tipo Referencia: https://sagemaker.readthedocs.io/en/stable/predictors.html ''' from sagemaker.predictor import csv_serializer, json_deserializer Xgboost_regressor.content_type = 'text/csv' Xgboost_regressor.serializer = csv_serializer Xgboost_regressor.deserializer = None X_test.shape
in []: in []:	<pre># Predicción predictions1 = Xgboost_regressor.predict(X_test[0:10000]) predictions2 = Xgboost_regressor.predict(X_test[10000:20000]) predictions3 = Xgboost_regressor.predict(X_test[20000:30000]) predictions4 = Xgboost_regressor.predict(X_test[30000:31618]) # código para convertir los valores en formato de bytes a una matriz</pre>
	<pre>def bytes_2_array(x): # realiza la predicción completa como un string y lo divide en función de ',' l = str(x).split(',') # Dado que el primer elemento contiene caracteres no deseados como (b, ',') los eliminamos l[0] = 1[0][2:] # lo mismo que arriba elimina el último carácter no deseado (') l[-1] = 1[-1][:-1] # iterando a través de la lista de cadenas y convirtiéndolas en tipo float for i in range(len(l)): 1[i] = float(l[i])</pre>
[n []:	<pre># convertimos la lista a array l = np.array(l).astype('float32') # redimensionamos la matriz unidimensional a una matriz bidimensional return l.reshape(-1,1) predicted_values_1 = bytes_2_array(predictions1) predicted_values_1.shape predicted_values_2 = bytes_2_array(predictions2) predicted_values_2.shape</pre>
n []: n []: n []:	<pre>predicted_values_3 = bytes_2_array(predictions3) predicted_values_3.shape predicted_values_4 = bytes_2_array(predictions4) predicted_values_4.shape predicted_values = np.concatenate((predicted_values_1, predicted_values_2, predicted_values_3, predicted_values_shape) from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error from math import sqrt</pre>
n []:	<pre>k = X_test.shape[1] n = len(X_test) RMSE = float(format(np.sqrt(mean_squared_error(y_test, predicted_values)),'.3f')) MSE = mean_squared_error(y_test, predicted_values) MAE = mean_absolute_error(y_test, predicted_values) r2 = r2_score(y_test, predicted_values) adj_r2 = 1-(1-r2)*(n-1)/(n-k-1) print('RMSE =',RMSE, '\nMSE =',MSE, '\nMAE =',MAE, '\nR2 =', r2, '\nAdjusted R2 =', adj_r2) # Eliminamos el end-point Xgboost_regressor.delete_endpoint()</pre>